

1/5/2025

Ensemble Learning

Ames Housing Dataset



Dr. F Keshavarze

Mohammad Mahdi Shafighi

SHAHED UNIVERSITY

| | |
|---|---|
| ۳ | ۱. توضیح داده‌ها و پیش‌پردازش‌های انجام‌شده : |
| ۳ | ۲. پیش‌پردازش داده‌ها شامل مراحل زیر بود: |
| ۳ | ۱. پاک‌سازی داده‌ها: |
| ۳ | ۲. تحلیل داده‌های اکتشافی: (EDA) |
| ۳ | ۳. مهندسی ویژگی‌ها: |
| ۴ | ۴. پیش‌پردازش نهایی داده‌ها: |
| ۴ | ۳. توضیح الگوریتم‌های پایه و روش‌های Ensemble |
| ۴ | • مدل‌های پایه: |
| ۴ | • روش‌های Ensemble: |
| ۴ | ۴. نتایج ارزیابی مدل‌ها |
| ۵ | ۵. نتایج ارزیابی مدل‌ها: |
| ۵ | تحلیل نتایج |
| ۶ | پیشنهادهای برای بهبود بیشتر |
| ۶ | ۱. تنظیم هایپرپارامترها: |
| ۶ | ۱.۱. افزایش ویژگی‌های مشتق‌شده: |
| ۶ | ۱.۱.۱. استفاده از Ensemble های پیچیده‌تر: |
| ۶ | ۱.۱.۲. بهبود داده‌ها: |
| ۶ | ۱.۱.۳. بررسی حذف ویژگی‌های کم‌اهمیت: |
| ۷ | جمع‌بندی: |

بسم الله الرحمن الرحيم

گزارش تحلیل و نتایج پروژه Ames Housing Data

۱. توضیح داده‌ها و پیش‌پردازش‌های انجام‌شده:

داده‌های استفاده‌شده شامل اطلاعات مرتبط با ویژگی‌های خانه‌ها و قیمت نهایی فروش آن‌ها استون SalePrice در منطقه Ames Iowa است. ویژگی‌ها به دو دسته کلی تقسیم می‌شوند:

ویژگی‌های عددی مانند GrLivArea، LotArea، و YearBuilt

ویژگی‌های غیر عددی مانند Neighborhood، BldgType، و HouseStyle

۲. پیش‌پردازش داده‌ها شامل مراحل زیر بود:

۱. پاکسازی داده‌ها:

- حذف مقادیر تکراری
- پر کردن مقادیر گم‌شده در ستون‌های عددی با مقدار میانه و در ستون‌های غیر عددی با پرتکرارترین مقدار
- حذف رکوردهایی که همچنان مقادیر گم‌شده داشتند.

۲. تحلیل داده‌های اکتشافی: (EDA)

- بررسی توزیع متغیر هدف (SalePrice) با استفاده از هیستوگرام.
- محاسبه ماتریس همبستگی ویژگی‌های عددی و نمایش آن با Heatmap
- ایجاد نمودار پراکندگی (scatter plot) برای بررسی رابطه GrLivArea و TotalBsmtSF با SalePrice

۳. مهندسی ویژگی‌ها:

- افزودن ویژگی جدید TotalLivingArea (مجموع مساحت زندگی در طبقات اصلی و زیرزمین)

۴. پیش‌پردازش نهایی داده‌ها:

- تقسیم داده‌ها به ویژگی‌ها (X) و متغیر هدف (y)
- دسته‌بندی ستون‌ها به ویژگی‌های عددی و غیر عددی
- استفاده از استاندارد سازی برای ستون‌های عددی و تبدیل OneHotEncoding برای ستون‌های غیر عددی

۳. توضیح الگوریتم‌های پایه و روش‌های Ensemble

- مدل‌های پایه:

Linear Regression: یک مدل خطی ساده که برای پیش‌بینی متغیرهای پیوسته استفاده می‌شود.

Decision Tree: الگوریتمی مبتنی بر درخت که تصمیمات را بر اساس بیشترین کاهش خطا (مانند MSE) اتخاذ می‌کند.

Random Forest: یک مدل Bagging که مجموعه‌ای از درخت‌های تصمیم‌گیری را ایجاد می‌کند و نتایج را ترکیب می‌کند.

• روش‌های Ensemble :

Bagging (Random Forest): الگوریتمی که نمونه‌گیری Bootstrap انجام داده و درخت‌های تصمیم متعدد را ترکیب می‌کند.

Boosting (Gradient Boosting): الگوریتمی که مدل‌های متوالی ایجاد کرده و خطای نمونه‌های قبلی را بهبود می‌دهد.

Stacking: ترکیب چندین مدل پایه (مانند Random Forest و Gradient Boosting) و آموزش یک مدل متا برای بهبود عملکرد.

۴. نتایج ارزیابی مدل‌ها

در این پروژه، از معیارهای زیر برای ارزیابی عملکرد مدل‌ها استفاده شد:

Mean Squared Error (MSE): میانگین مربع خطاها.

Root Mean Squared Error (RMSE): ریشه دوم میانگین مربع خطاها.

R^2 Score: میزان واریانس توضیح داده شده توسط مدل. (اضافی شده)

۵. نتایج ارزیابی مدل‌ها:

مدل‌های Bagging، Boosting، و Stacking با استفاده از داده‌های Ames Housing مورد ارزیابی قرار گرفتند که نتایج از این قرار می‌باشد:

| مدل | MAE | RMSE | MSE | R^2 Score |
|----------|-----------|-----------|----------------|-------------|
| Bagging | 15,823.80 | 26,404.82 | 697,214,755.73 | 0.9130 |
| Boosting | 15,249.18 | 26,583.14 | 706,663,100.46 | 0.9119 |
| Stacking | 17,135.91 | 27,230.19 | 741,483,154.40 | 0.9075 |

تحلیل نتایج

۱. Bagging (Random Forest)

- بهترین عملکرد در معیارهای MAE و RMSE.
- این مدل توانایی بسیار خوبی در کاهش خطاهای پیش‌بینی دارد، به دلیل استفاده از چندین درخت تصمیم و ترکیب نتایج آن‌ها.

۲. Boosting (Gradient Boosting)

- عملکرد کمی ضعیف‌تر از Bagging در معیارهای RMSE و R^2 Score.
- مدل Boosting به دلیل افزایش تدریجی و بهبود خطاهای مدل‌های قبلی، مناسب پیش‌بینی‌های پیچیده‌تر است.

۳. Stacking

- عملکرد نسبتاً ضعیف‌تر در مقایسه با Bagging و Boosting

- این مدل به دلیل پیچیدگی بیشتر و وابستگی به کیفیت مدل‌های پایه، ممکن است در داده‌های خاص کارایی پایین‌تری داشته باشد.

پیشنهادهای برای بهبود بیشتر

I. تنظیم هایپرپارامترها:

- استفاده از GridSearchCV یا RandomizedSearchCV برای یافتن بهترین مقادیر هایپرپارامترهای مدل‌ها.
- برای مثال:

▪ تعداد درخت‌ها (n_estimators) و عمق درخت‌ها (max_depth) در Random Forest.

▪ نرخ یادگیری (learning_rate) و تعداد مراحل تقویت در Gradient Boosting

II. افزایش ویژگی‌های مشتق‌شده:

- شناسایی و افزودن ویژگی‌های جدید مانند تعامل بین متغیرها یا استفاده از تحلیل‌های دامنه تخصصی (مانند نسبت مساحت زیرزمین به کل مساحت خانه).

III. استفاده از Ensemble های پیچیده‌تر:

- ترکیب مدل‌های دیگری مانند XGBoost یا LightGBM با مدل‌های فعلی.

IV. بهبود داده‌ها:

- افزایش تعداد داده‌ها یا استفاده از تکنیک‌هایی مانند Data Augmentation برای کاهش خطاها.

V. بررسی حذف ویژگی‌های کم‌اهمیت:

- ویژگی‌هایی که همبستگی کمتری با متغیر هدف دارند، می‌توانند حذف شوند تا پیچیدگی مدل کاهش یابد.

جمع‌بندی:

مدل Bagging با MAE کمترین و R^2 Score بالاترین، بهترین عملکرد را در این تحلیل ارائه داد. مدل‌های Boosting و Stacking نیز با وجود پیچیدگی بیشتر، عملکرد قابل قبولی داشتند. برای بهبود بیشتر، تنظیم دقیق هایپرپارامترها و استخراج ویژگی‌های جدید پیشنهاد می‌شود.